DSC

DATA SCIENCE COMPETITION

PT AYASKARA NISITA SYNERGY
Market Research and Management Consultants

starcore.co

PENDAHULUAN

Kelemahan sistem referensi perpustakaan **menghambat akses pengetahuan.**

Hambatan dalam **sistem referensi** menyebabkan kesulitan dalam **mengakses** dan **memilih referensi yang sesuai** untuk karya ilmiah.

Kesulitan dalam **mengakses** dan **memilih referensi** yang sesuai untuk **karya ilmiah** akan **menghambat** proses **penelitian** dan **mengurangi kualitas** hasil **penelitian**.

Lalu, **apa yang dapat dilakukan?**

OBJEKTIF

Mengoptimalkan sistem referensi untuk **mempercepat akses informasi** dan **mendukung kualitas penelitian.**

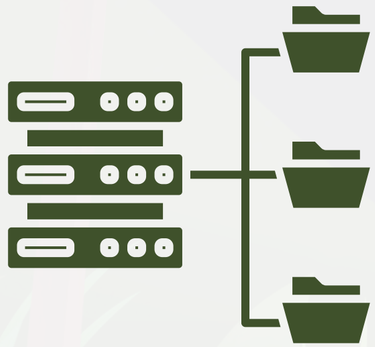

Membuat **perencanaan** untuk **meningkatkan efisiensi** akses informasi dan **mendukung kualitas penelitian**.

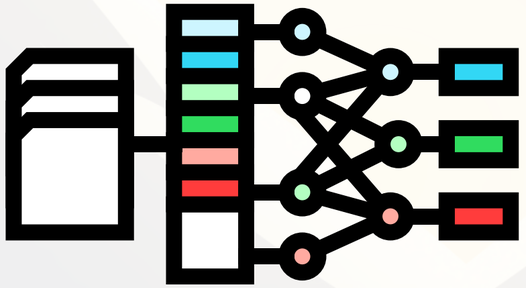

Mengoptimalkan sistem referensi melalui penerapan **model machine learning** untuk prediksi **hubungan** antar **paper**

Menerapkan solusi sistem rekomendasi referensi guna **meningkatkan efektivitas** dan **akurasi pencarian literatur**.

ALUR PENELITIAN

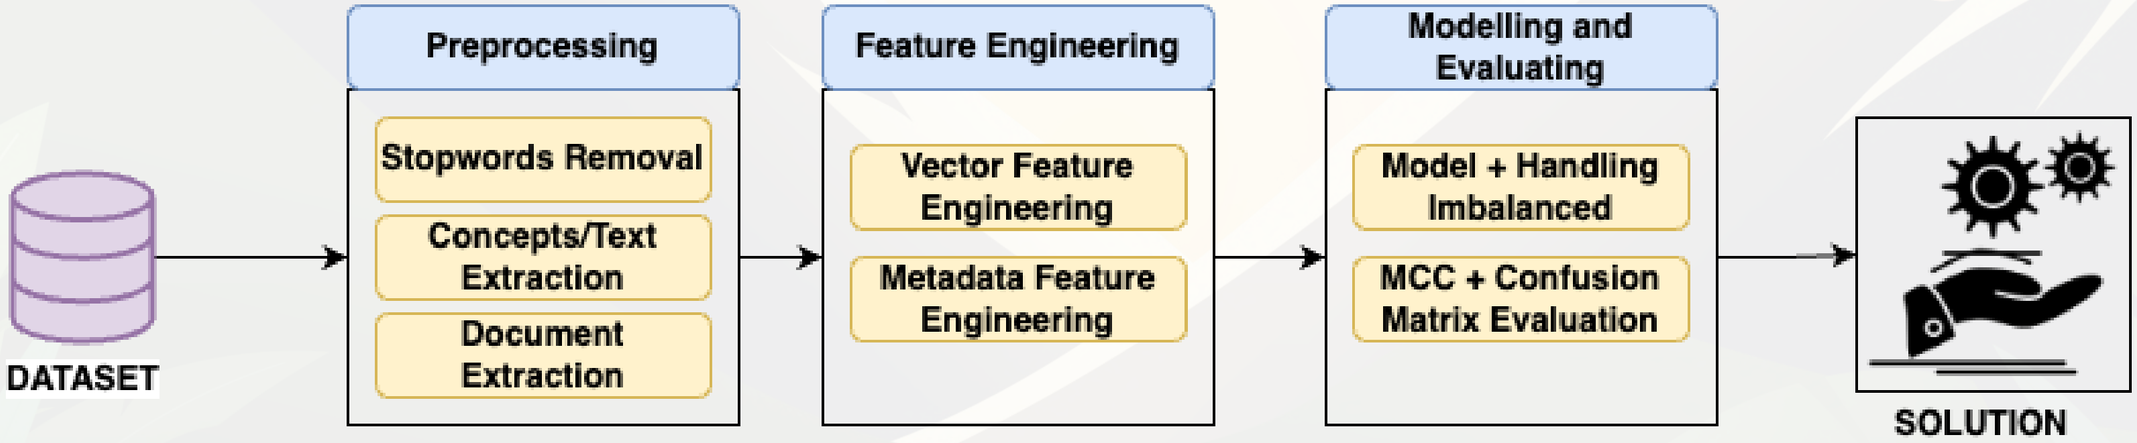

DATA PREPROCESSING

PT AYASKARA NISITA SYNERGY
Market Research and Management Consultants

starcore.co

Document

PAPER ID

Department of Medicine and Institute for Human Genetics, University of California, San Francisco, and California Institute for Quantitative Biosciences, San Francisco, CA t from such learning approaches and use examples from the literature to introduce basic concepts in machine learning. It is important to note.

Dokumen berupa teks akademik yang secara mendalam mengulas suatu topik tertentu dalam bentuk pembahasan yang panjang dan terstruktur.

Metadata

Paper	Title	Concepts	...	Publication Year
p0000	Machine Learning in Medicine	AI;Machine Learning	..	2015
p0001	A literature ... problems	Benchmark; Compsci	..	1998
p0002	Gaussian .... Motion	AI;Compsci	..	2007
...	...	...	...	...
p4358	Applied ... Physic	Physic;Medical	..	2002

Metadata berupa tabel dengan 17 kolom, terdiri dari kolom bertipe string, seperti kategori dan data tidak terstruktur seperti judul atau konsep dari sebuah jurnal, serta kolom bertipe numerik.

DOCUMENT EMBEDDING

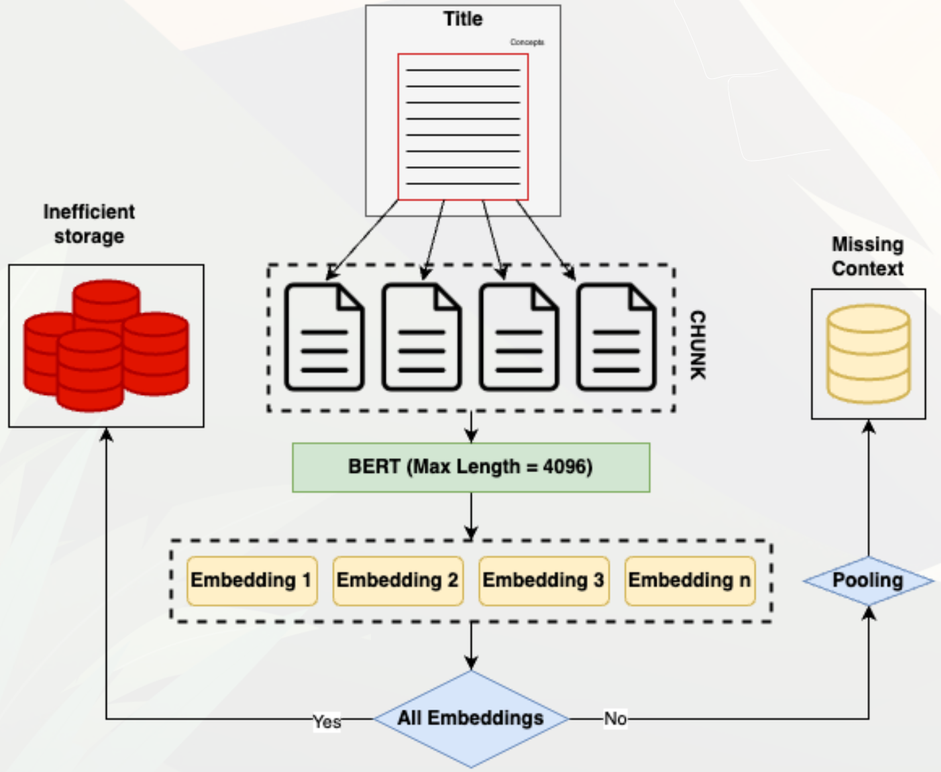

BERT Extraction

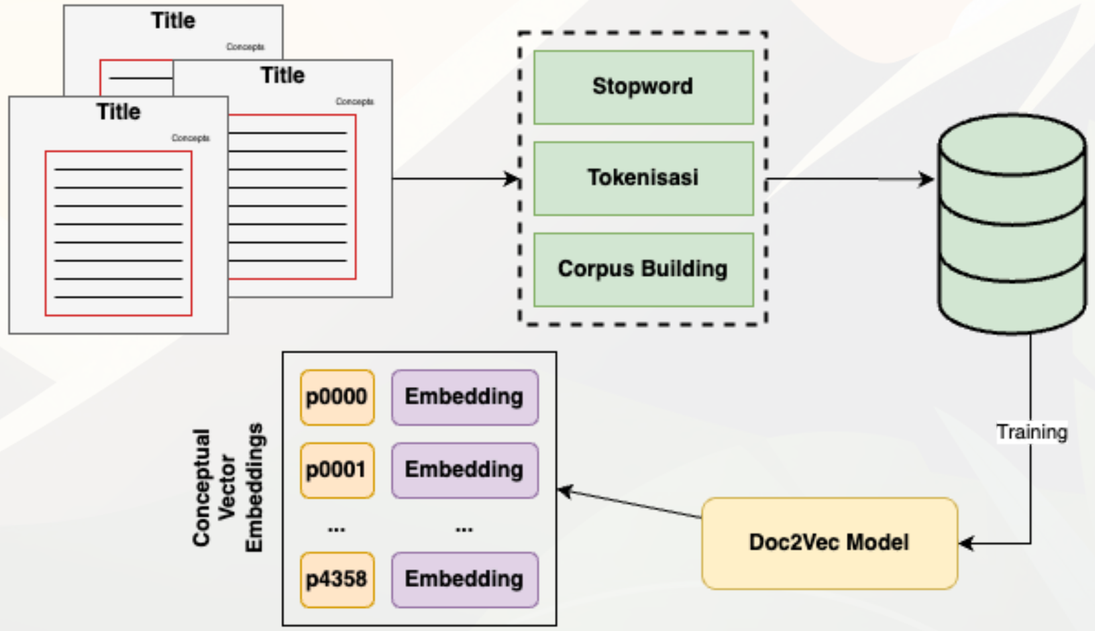

Doc2Vec Extraction

DOCUMENT EMBEDDING COMPARISON

Aspek	Doc2Vec	BERT/Transformer-Based
Kebutuhan Sumber Daya	Ringan, tidak perlu GPU ✅	Butuh GPU & RAM besar untuk pelatihan/ekstraksi
Pemahaman Konteks	Cukup baik, konteks berdasarkan urutan kata	Sangat baik, konteks dua arah (bidirectional) ✅
Dokumen Panjang	Sangat cocok, tidak dibatasi panjang input ✅	Terbatas (umumnya 512 token), kecuali model khusus seperti Longformer
Kecepatan Pelatihan	Cepat, lebih ringan dan langsung bisa memproses dokumen panjang ✅	Relatif lebih lambat karena model besar dan perlu membagi dokumen panjang menjadi chunk terlebih dahulu

Doc2Vec dipilih karena efisien secara komputasi, murah, mampu menangani dokumen panjang, dan memberikan hasil yang cukup baik tanpa memerlukan sumber daya besar seperti BERT.

METADATA EMBEDDING

Paper	Title	Concepts	...	Publication Year
p0000	Machine Learning in Medicine	AI;Machine Learning	..	2015
p0001	A literature ... problems	Benchmark; Compsci	..	1998
p0002	Gaussian .... Motion	AI;Compsci	..	2007
...	...	...	...	...
p4358	Applied ... Physic	Physic;Medical	..	2002

Title Embedding

Concepts Embedding

METADATA EMBEDDING

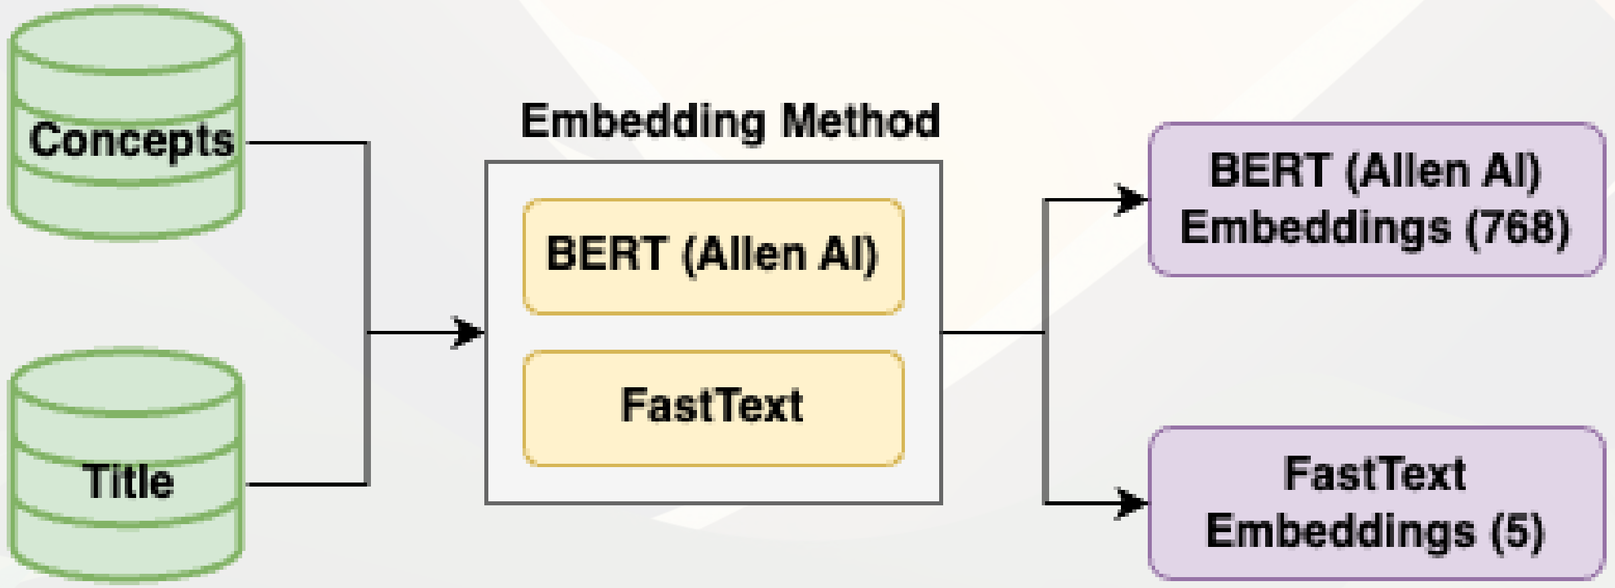

FEATURE ENGINEERING

PT AYASKARA NISITA SYNERGY
Market Research and Management Consultants

starcore.co

VECTOR FEATURE ENGINEERING

DISTANCE CALCULATION (2 VECTOR)

- Cosine Similarity
- Euclidian Distance
- Manhattan Distance
- Pearson Correlation

SCALAR CALCULATION (2 VECTOR)

- Mean Combined
- Standar Deviation Diff
- Squared Diff Sumation
- Absolute Diff Sumation

PROJECTION CALCULATION (2 VECTOR)

- Vector Projection

ANGULAR CALCULATION (2 VECTOR)

- Angular Cosine Similarity

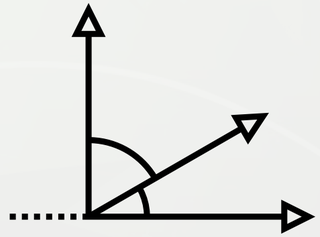

METADATA FEATURE ENGINEERING

NORMALIZED PUBLICATION YEAR (2 PAPER)

- Now Year Diff
- Diff Age
- Diff Ratio
- Ratio Age

DATE TIME EXTRACTION (2 PAPER)

- Diff Date
- Diff Month
- Diff Week
- Diff Year

AUTHOR AND JOURNAL NAME EXTRACTION

- Primary Author
- Journal Name

CITED COUNT EXTRACTION

- CITATION DIFF
- CITATION RATIO

KEY POINTS

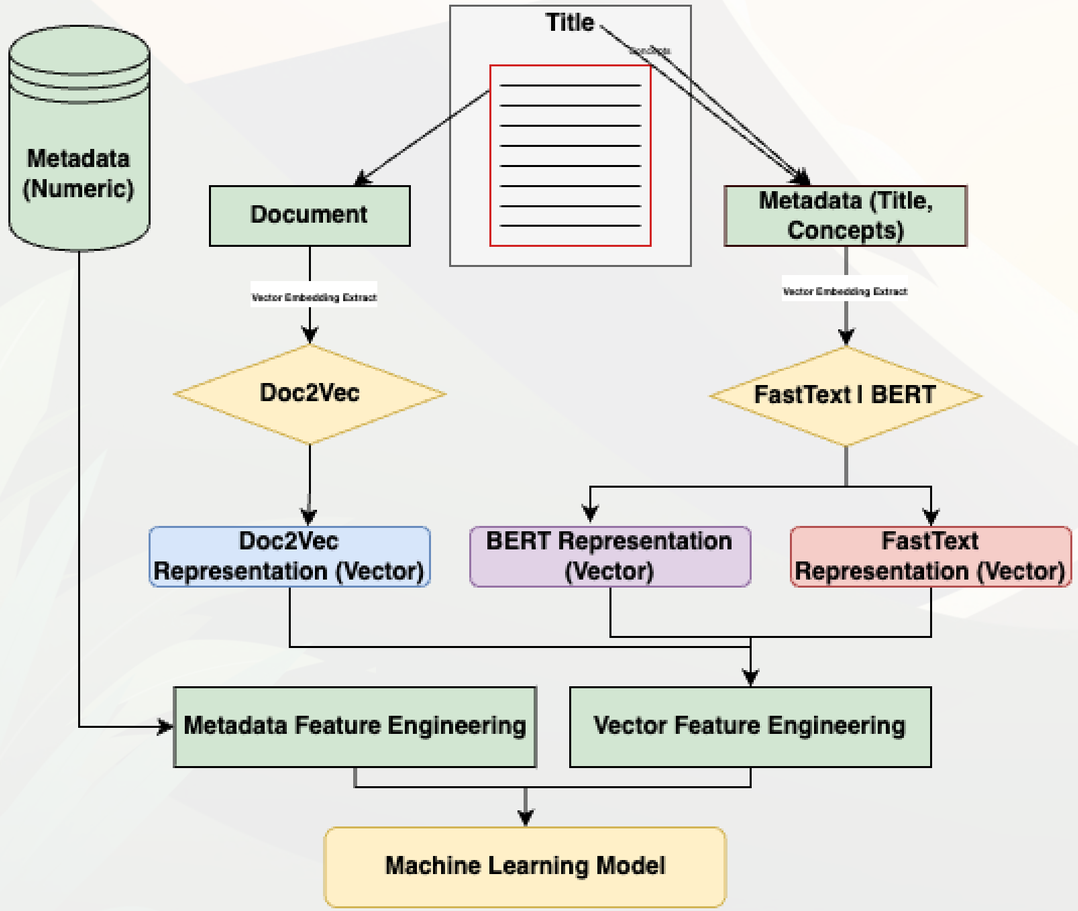

Document Representation

Metadata Representation

MODELLING

PT AYASKARA NISITA SYNERGY
Market Research and Management Consultants

starcore.co

MODEL EXPERIMENT FLOW

Model	MCC
CatBoost + TF IDF Document + Metadata Mentah	0.32
CatBoost Tuned + TF IDF + TF IDF Document + Metadata Mentah	0.33
LGBM Tuned + TF IDF + Cosine Document + Metadata Mentah	0.41
RandomForest Tuned + TF IDF + Cosine Document + Metadata Mentah	0.47
CatBoost + Doc2Vec Document + Metadata Mentah	0.5

MODEL EXPERIMENT FLOW

Model	MCC
CatBoost + Doc2Vec Document + Fast Text (Concepts + Title) + Metadata Mentah	0.518
CatBoost + Doc2Vec Document + Fast Text (Concepts + Title) + FE Metadata	0.52
CatBoost + Doc2Vec Document + Fast Text (Concepts + Title) + BERT (Concepts + Title) + FE Metadata + FE Vector Embeddings	0.54
CatBoost Tuned + Doc2Vec Document + Fast Text (Concepts + Title) + BERT (Concepts + Title) + FE Metadata + FE Vector Embeddings	0.568

BEST MODEL EVALUATE

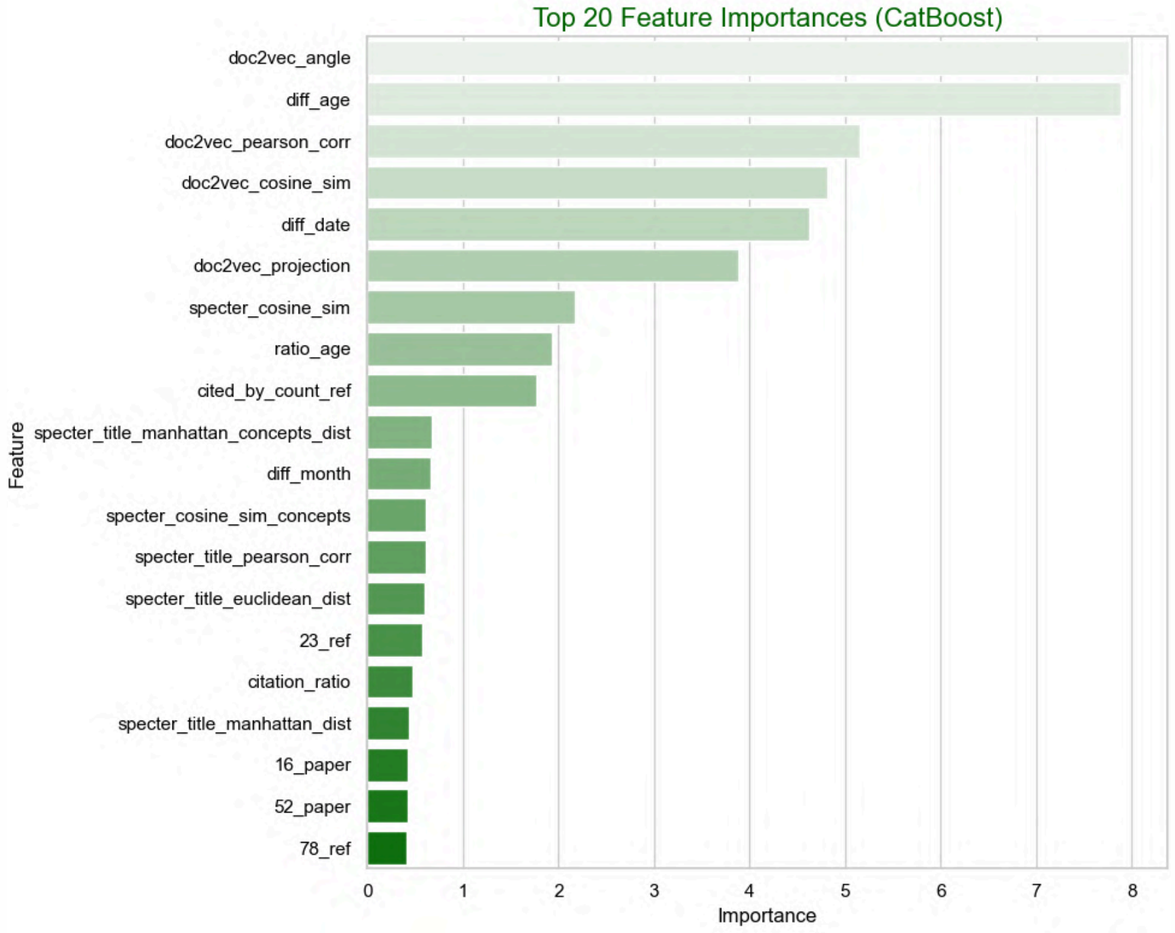

Confusion Matrix

69045	44
527	192

Model masih mengalami kesalahan dalam mengklasifikasikan kelas minoritas, namun karena menggunakan MCC (Matthews Correlation Coefficient), evaluasi tetap adil meskipun data tidak seimbang.

CONCLUSION

1. Pemanfaatan NLP (representasi **vektor embedding**) merupakan **kunci** dalam merepresentasikan sebuah dokumen. Selain itu tanggal **penerbitan** juga menjadi **kunci** untuk **mendeteksi hubungan** antar dokumen
2. Hubungan antar dokumen dapat **direpresentasikan** secara matematis dengan **menghitung dua vektor embedding** antar dokumen.
3. Model Machine Learning Sederhana dapat membangun sistem referensi standar yang cukup baik dengan skor MCC sekitar **0,568** mendekati **0,57**.
4. Dengan **biaya yang cukup murah**, cara ini dapat menghasilkan **hasil** yang **cukup baik**

THANK YOU